

Datenstrukturen und Algorithmen

Vorlesung 13: Hashing II

Joost-Pieter Katoen

Lehrstuhl für Informatik 2
Software Modeling and Verification Group

<https://moves.rwth-aachen.de/teaching/ss-18/dsal/>

11. Juni 2018

Übersicht

1 Hashing und Verkettung

2 Offene Adressierung

- Lineares Sondieren
- Quadratisches Sondieren
- Doppeltes Hashing
- Effizienz der offenen Adressierung

Übersicht

1 Hashing und Verkettung

2 Offene Adressierung

- Lineares Sondieren
- Quadratisches Sondieren
- Doppeltes Hashing
- Effizienz der offenen Adressierung

Hashing

Das Ziel von **Hashing** ist:

- ▶ Einen extrem großen Schlüsselraum auf einen vernünftig kleinen Bereich von ganzen Zahlen abzubilden.

Hashing

Das Ziel von **Hashing** ist:

- ▶ Einen extrem großen Schlüsselraum auf einen vernünftig kleinen Bereich von ganzen Zahlen abzubilden.
- ▶ Dass zwei Schlüssel auf die selbe Zahl abgebildet werden, soll möglichst unwahrscheinlich sein.

Hashing

Das Ziel von **Hashing** ist:

- ▶ Einen extrem großen Schlüsselraum auf einen vernünftig kleinen Bereich von ganzen Zahlen abzubilden.
- ▶ Dass zwei Schlüssel auf die selbe Zahl abgebildet werden, soll möglichst unwahrscheinlich sein.

Hashfunktion, Hashtabelle, Hashkollision

Eine **Hashfunktion** bildet einen Schlüssel auf einen Index der **Hashtabelle** T ab:

$$h : U \longrightarrow \underbrace{\{0, 1, \dots, m-1\}}_{\text{Univ. der Schlüssel}} \quad \text{für Tabellengröße } m \text{ und } |U| = N$$

*Universum
der Schlüssel*

$m \ll N$

$$h(i) = r \quad 0 \leq r < m \quad T[r]$$

Hashing

Das Ziel von **Hashing** ist:



- ▶ Einen extrem großen Schlüsselraum auf einen vernünftig kleinen Bereich von ganzen Zahlen abzubilden.
- ▶ Dass zwei Schlüssel auf die selbe Zahl abgebildet werden, soll möglichst unwahrscheinlich sein.

Hashfunktion, Hashtabelle, Hashkollision

Eine **Hashfunktion** bildet einen Schlüssel auf einen Index der **Hashtabelle** T ab:

$$h : U \longrightarrow \{0, 1, \dots, m-1\} \text{ für Tabellengröße } m \text{ und } |U| = \aleph_0$$

Wir sagen, dass $h(k)$ der **Hashwert** des Schlüssels k ist.

Hashing

Das Ziel von **Hashing** ist:

- ▶ Einen extrem großen Schlüsselraum auf einen vernünftig kleinen Bereich von ganzen Zahlen abzubilden.
- ▶ Dass zwei Schlüssel auf die selbe Zahl abgebildet werden, soll möglichst unwahrscheinlich sein.

Hashfunktion, Hashtabelle, Hashkollision

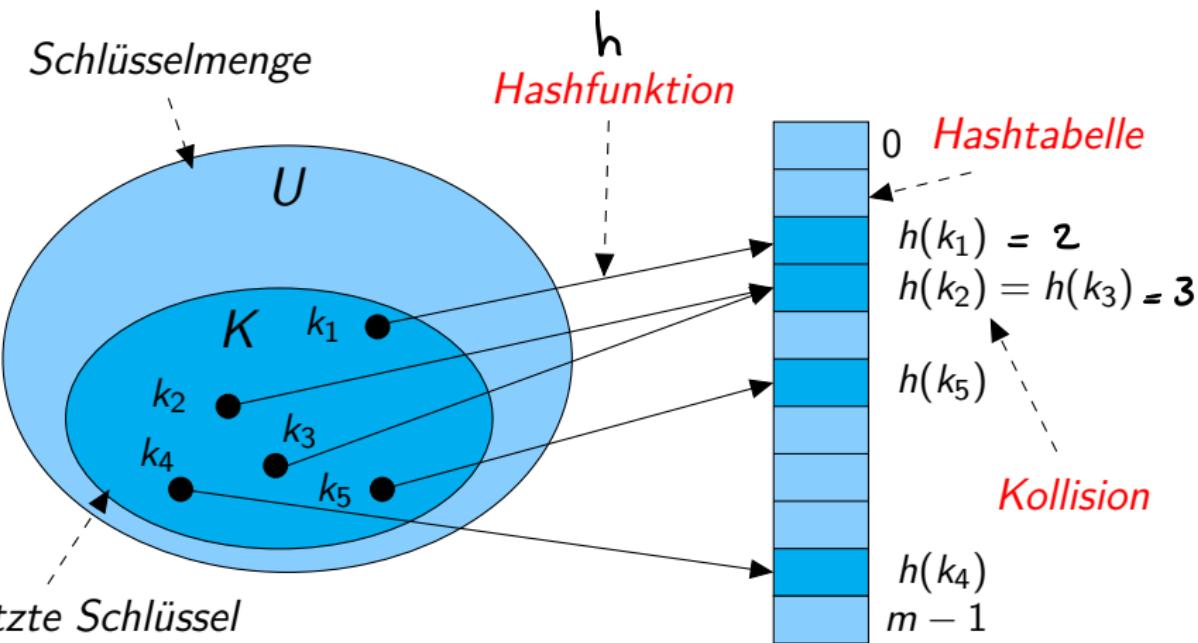
Eine **Hashfunktion** bildet einen Schlüssel auf einen Index der **Hashtabelle** T ab:

$$h : U \longrightarrow \{0, 1, \dots, m-1\} \text{ für Tabellengröße } m \text{ und } |U| = \aleph_0$$

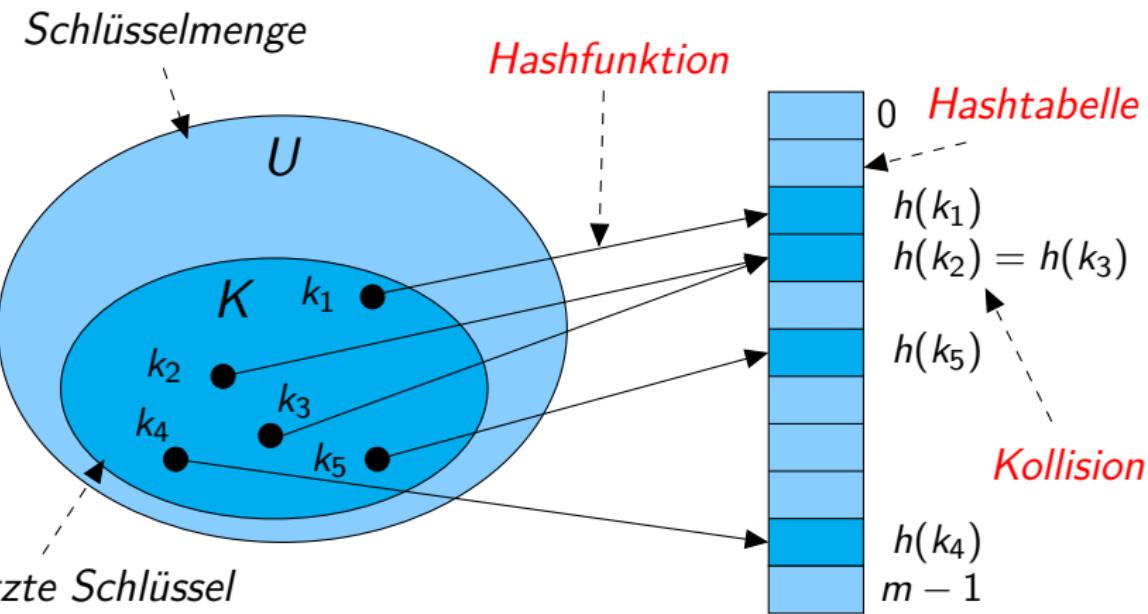
Wir sagen, dass $h(k)$ der **Hashwert** des Schlüssels k ist.

Das Auftreten von $h(k) = h(k')$ für $k \neq k'$ nennt man eine **Kollision**.

Hashing



Hashing



- ▶ Wie behandeln wir dennoch auftretende Kollisionen?
- ▶ Zwei Varianten: Verkettung und Offene Adressierung

Kollisionsauflösung durch Verkettung (I)

Idee

Alle Schlüssel, die zum gleichen Hash führen, werden in einer **verketteten Liste** gespeichert.

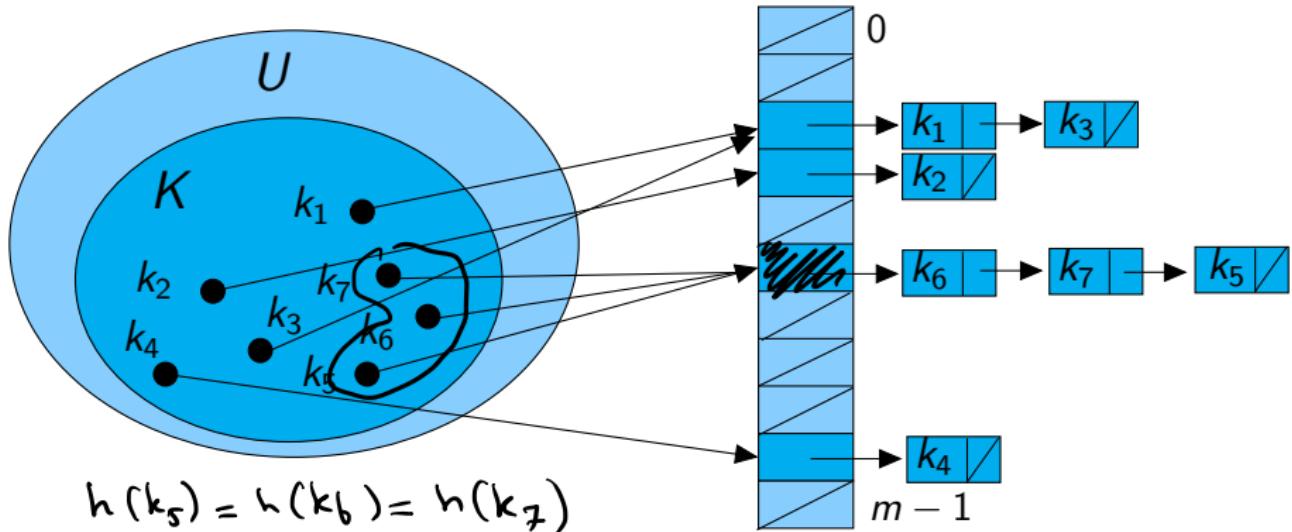
[Luhn 1953]

Kollisionsauflösung durch Verkettung (I)

Idee

Alle Schlüssel, die zum gleichen Hash führen, werden in einer **verketteten Liste** gespeichert.

[Luhn 1953]



Average-Case-Analyse von Verkettung

Erfolgreiche Suche

Die erfolgreiche Suche benötigt im Average-Case $\Theta(1 + \alpha)$.

$$\alpha = \frac{n}{m}$$

Fullgrad

n = Anzahl belegter slots in T

$$|T| = m \ll N = |U|$$

Average-Case-Analyse von Verkettung

 $\Theta(1)$

Erfolgreiche Suche

Die erfolgreiche Suche benötigt im Average-Case $\Theta(1 + \alpha)$.

Erfolglose Suche

Die erfolglose Suche benötigt im Average-Case $\Theta(1 + \alpha)$.

$$\alpha = \frac{n}{m} \quad \underline{n \in O(m)}$$

Übersicht

1 Hashing und Verkettung

2 Offene Adressierung

- Lineares Sondieren
- Quadratisches Sondieren
- Doppeltes Hashing
- Effizienz der offenen Adressierung

Kollisionsauflösung durch **offene Adressierung**

- ▶ Alle Elemente werden direkt in der Hashtabelle gespeichert (im Gegensatz zur Verkettung).

Kollisionsauflösung durch offene Adressierung

- ▶ Alle Elemente werden direkt in der Hashtabelle gespeichert (im Gegensatz zur Verkettung).
- ⇒ Höchstens m Schlüssel können gespeichert werden, d. h.
 $\alpha(n, m) = \frac{n}{m} \leq 1$. [Amdahl 1954]

Kollisionsauflösung durch offene Adressierung

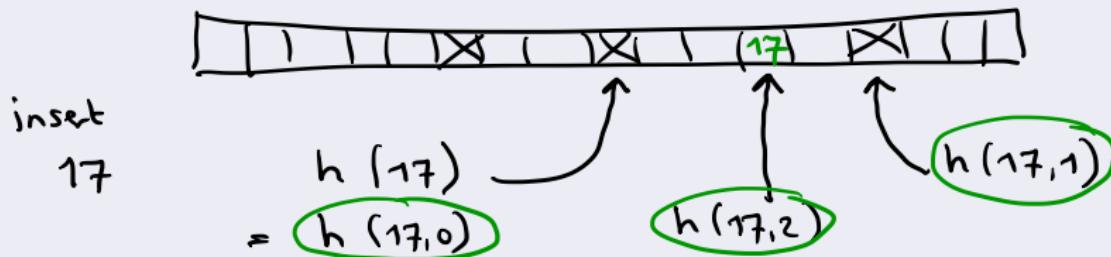
- ▶ Alle Elemente werden direkt in der Hashtabelle gespeichert (im Gegensatz zur Verkettung).
- ⇒ Höchstens m Schlüssel können gespeichert werden, d. h.
$$\alpha(n, m) = \frac{n}{m} \leqslant 1.$$
 [Amdahl 1954]
- ▶ Man spart aber den Platz für die Pointer.

Kollisionsauflösung durch offene Adressierung

- Alle Elemente werden direkt in der Hashtabelle gespeichert (im Gegensatz zur Verkettung).
- ⇒ Höchstens m Schlüssel können gespeichert werden, d. h.
 $\alpha(n, m) = \frac{n}{m} \leq 1$. [Amdahl 1954]
- Man spart aber den Platz für die Pointer.

Einfügen von Schlüssel k

- Sondiere (to probe) die Positionen der Hashtabelle, bis ein leerer Slot gefunden wurde.



Kollisionsauflösung durch offene Adressierung

- ▶ Alle Elemente werden direkt in der Hashtabelle gespeichert (im Gegensatz zur Verkettung).
- ⇒ Höchstens m Schlüssel können gespeichert werden, d. h.
 $\alpha(n, m) = \frac{n}{m} \leqslant 1$. [Amdahl 1954]
- ▶ Man spart aber den Platz für die Pointer.

Einfügen von Schlüssel k

- ▶ **Sondiere** (to probe) die Positionen der Hashtabelle, bis ein leerer Slot gefunden wurde.
- ▶ Die zu überprüfenden Positionen sind vom einzufügenden Schlüssel k abgeleitet.

17

Kollisionsauflösung durch offene Adressierung

- ▶ Alle Elemente werden direkt in der Hashtabelle gespeichert (im Gegensatz zur Verkettung).
- ⇒ Höchstens m Schlüssel können gespeichert werden, d. h.
 $\alpha(n, m) = \frac{n}{m} \leq 1$. [Amdahl 1954]
- ▶ Man spart aber den Platz für die Pointer.

Einfügen von Schlüssel k

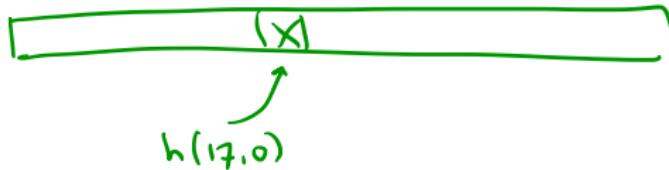
- ▶ Sondiere (to probe) die Positionen der Hashtabelle, bis ein leerer Slot gefunden wurde.
- ▶ Die zu überprüfenden Positionen sind vom einzufügenden Schlüssel k abgeleitet.
 $h(17,0)$ $h(17,1)$ $h(17,2)$
- ▶ Die Hashfunktion hängt also vom Schlüssel k und der Nummer der Sondierung ab:
 $h(17, m-1)$

$$h : U \times \underbrace{\{0, 1, \dots, m-1\}}_{\text{Sondierung}} \longrightarrow \underbrace{\{0, 1, \dots, m-1\}}_{\text{Hashtabelle}}$$

Einfügen bei offener Adressierung

```
1 void hashInsert(int T[], int key) {
2     for (int i = 0; i < T.length; i++) { // Teste ganze Tabelle
3         int pos = h(key, i); // Berechne i-te Sondierung
4         if (!T[pos]) { // freier Platz
5             T[pos] = key;
6             return; // fertig
7         }
8     }
9     throw "Überlauf der Hashtabelle";
10 }
```

$h(17,0)$
 $h(17,1)$
}



Suche bei offener Adressierung

```
1 int hashSearch(int T[], int key) {
2     for (int i = 0; i < T.length; i++) {
3         int pos = h(key, i); // Berechne i-te Sondierung
4         if (T[pos] == key) { // Schlüssel k gefunden
5             return T[pos];
6         } else if (!T[pos]) { // freier Platz, nicht gefunden
7             break;
8         }
9     }
10    return -1; // "nicht gefunden"
11 }
```

Löschen bei offener Adressierung

Löschen bei offener Adressierung

Problem

*Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist **ungeeignet**:*

Löschen bei offener Adressierung

Problem

Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist ungeeignet:

- Wenn beim Einfügen von k der Slot i besetzt war, können wir k nicht mehr abrufen.

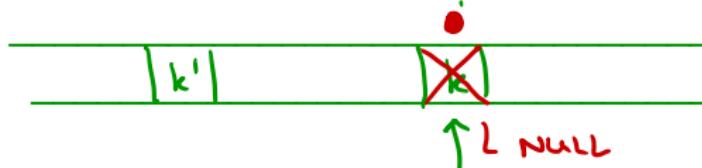


sei k' nach k eingefügt in T

und beim Einfügen von k' wurde mal sondiert

so daß $h(k', j) = i$

suche k'
nachdem k
gelöscht wurde



$h(k', j+1)$

$h(k', j+2)$

Löschen bei offener Adressierung

Problem

*Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist **ungeeignet**:*

- Wenn beim Einfügen von k der Slot i besetzt war, können wir k nicht mehr abrufen.

Lösung

Markiere $T[i]$ mit dem **speziellen Wert** DELETED (oder: „veraltet“).



Löschen bei offener Adressierung

Problem

Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist ungeeignet:

- ▶ Wenn beim Einfügen von k der Slot i besetzt war, können wir k nicht mehr abrufen.

Lösung

Markiere $T[i]$ mit dem speziellen Wert DELETED (oder: „veraltet“).

- ▶ hashInsert muss angepasst werden und solche Slots als leer betrachten.

Löschen bei offener Adressierung

Problem

Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist ungeeignet:

- ▶ Wenn beim Einfügen von k der Slot i besetzt war, können wir k nicht mehr abrufen.

Lösung

Markiere $T[i]$ mit dem speziellen Wert DELETED (oder: „veraltet“).

- ▶ hashInsert muss angepasst werden und solche Slots als leer betrachten.
- ▶ hashSearch bleibt unverändert, solche Slots werden einfach übergangen.

Löschen bei offener Adressierung

Problem

*Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist **ungeeignet**:*

- ▶ Wenn beim Einfügen von k der Slot i besetzt war, können wir k nicht mehr abrufen.

Lösung

*Markiere $T[i]$ mit dem **speziellen Wert** DELETED (oder: „veraltet“).*

- ▶ hashInsert muss angepasst werden und solche Slots als leer betrachten.
- ▶ hashSearch bleibt unverändert, solche Slots werden einfach übergangen.
- ▶ Die Suchzeiten sind nun nicht mehr allein vom Füllgrad α abhängig.

Löschen bei offener Adressierung

Problem

*Löschen des Schlüssels k aus Slot i durch $T[i] = \text{null}$ ist **ungeeignet**:*

- ▶ Wenn beim Einfügen von k der Slot i besetzt war, können wir k nicht mehr abrufen.

Lösung

*Markiere $T[i]$ mit dem **speziellen Wert** DELETED (oder: „veraltet“).*

- ▶ hashInsert muss angepasst werden und solche Slots als leer betrachten.
 - ▶ hashSearch bleibt unverändert, solche Slots werden einfach übergangen.
-
- ▶ Die Suchzeiten sind nun nicht mehr allein vom Füllgrad α abhängig.
 - ⇒ Wenn Schlüssel gelöscht werden sollen wird häufiger **Verkettung** verwendet.

Wie wählt man die nächste Sondierung?

$h(17,0)$ }
 $h(17,1)$ }
 $h(17,2)$
:
:

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle \underline{h(k, 0)}, \underline{h(k, 1)}, \dots, \underline{h(k, m-1)} \rangle$$

*m Position
in T*

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle h(k, 0), h(k, 1), \dots, h(k, m-1) \rangle$$

- Wenn es sich dabei um eine Permutation von $\langle 0, \dots, m-1 \rangle$ handelt ist garantiert, dass jeder Slot letztlich geprüft wird.

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle h(k, 0), h(k, 1), \dots, h(k, m-1) \rangle$$

- Wenn es sich dabei um eine Permutation von $\langle 0, \dots, m-1 \rangle$ handelt ist garantiert, dass jeder Slot letztlich geprüft wird.
- Gleichverteiltes Hashing wäre ideal, d. h. jede der $m!$ Permutationen ist als Sondierungssequenz gleich wahrscheinlich.

m Positionen

$m!$ Permutationen

$$\Pr(\text{Permutation } x) = \frac{1}{m!}$$

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle h(k, 0), h(k, 1), \dots, h(k, m-1) \rangle$$

- ▶ Wenn es sich dabei um eine Permutation von $\langle 0, \dots, m-1 \rangle$ handelt ist garantiert, dass jeder Slot letztlich geprüft wird.
- ▶ **Gleichverteiltes** Hashing wäre ideal, d. h. jede der $m!$ Permutationen ist als Sondierungssequenz gleich wahrscheinlich.
- ▶ In der Praxis ist das aber zu aufwändig und wird approximiert.

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle h(k, 0), h(k, 1), \dots, h(k, m-1) \rangle$$

- ▶ Wenn es sich dabei um eine Permutation von $\langle 0, \dots, m-1 \rangle$ handelt ist garantiert, dass jeder Slot letztlich geprüft wird.
- ▶ **Gleichverteiltes** Hashing wäre ideal, d. h. jede der $m!$ Permutationen ist als Sondierungssequenz gleich wahrscheinlich.
- ▶ In der Praxis ist das aber zu aufwändig und wird approximiert.

Sondierungsverfahren

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle h(k, 0), h(k, 1), \dots, h(k, m-1) \rangle$$

- ▶ Wenn es sich dabei um eine Permutation von $\langle 0, \dots, m-1 \rangle$ handelt ist garantiert, dass jeder Slot letztlich geprüft wird.
- ▶ **Gleichverteiltes** Hashing wäre ideal, d. h. jede der $m!$ Permutationen ist als Sondierungssequenz gleich wahrscheinlich.
- ▶ In der Praxis ist das aber zu aufwändig und wird approximiert.

Sondierungsverfahren

- ▶ Wir behandeln **Lineares Sondieren**, **Quadratisches Sondieren** und **Doppeltes Hashing**.

Wie wählt man die nächste Sondierung?

Wir benötigen eine **Sondierungssequenz** für einen gegebenen Schlüssel k :

$$\langle h(k, 0), h(k, 1), \dots, h(k, m-1) \rangle$$

- ▶ Wenn es sich dabei um eine Permutation von $\langle 0, \dots, m-1 \rangle$ handelt ist garantiert, dass jeder Slot letztlich geprüft wird.
- ▶ **Gleichverteiltes** Hashing wäre ideal, d. h. jede der $m!$ Permutationen ist als Sondierungssequenz gleich wahrscheinlich.
- ▶ In der Praxis ist das aber zu aufwändig und wird approximiert.

Sondierungsverfahren

- ▶ Wir behandeln **Lineares Sondieren**, **Quadratisches Sondieren** und **Doppeltes Hashing**.
- ▶ Die Qualität ist durch die Anzahl der verschiedenen Sondierungssequenzen, die jeweils erzeugt werden, bestimmt.

Lineares Sondieren

$$\underbrace{h'(k) + i}_{\text{Linear}} \quad \{0, \dots, m-1\}$$

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \quad (\text{für } i < m).$$

- ▶ k ist der Schlüssel
- ▶ i ist der Index im Sondierungssequenz
- ▶ h' ist eine übliche Hashfunktion.

Lineares Sondieren: Beispiel

$$m=11$$

*

22	0
1	1
2	2
3	3
4	4
15	5
28	6
7	7
8	8
31	9
10	10

22	0
1	1
2	2
3	3
4	4
15	5
28	6
6	7
7	8
8	9
31	10

22	0
1	1
2	2
3	3
4	4
15	5
28	6
17	7
8	8
31	9
10	10

ins(17) →
1. Sondierung

ins(17) →
2. Sondierung

$$h(17, 0) =$$

$$\underbrace{(h'(17) + 0)}_{6} \bmod 11 = 6 \quad \downarrow$$

$$h(6) = 28$$

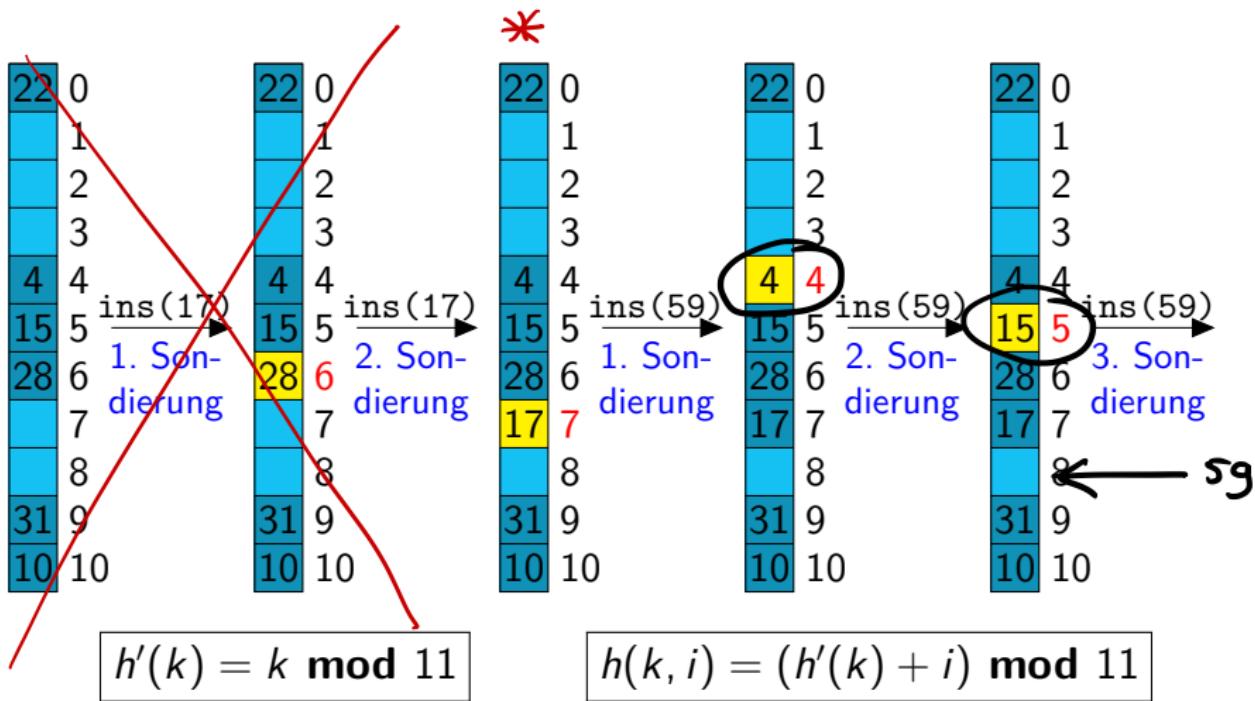
$$h(17, 1) =$$

$$(6+1) \bmod 11 = 7$$

$$h'(k) = k \bmod 11$$

$$h(k, i) = (h'(k) + i) \bmod 11$$

Lineares Sondieren: Beispiel



$$h(59, 0) = \left(\underbrace{h'(59)}_{59 \bmod 11} + 0 \right) \bmod 11$$

$$\begin{array}{c} 59 \bmod 11 \\ \hline 4 \end{array}$$

$$= 4$$

$$h(59, 1) = (4 + 1) \bmod 11$$

$$= 5$$

$$h(59, 2) = 6$$

$$h(59, 3) = 7$$

$$h(59, 4) = 8 \quad \text{:-)}$$

Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion.

Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \text{ (für } i < m\text{).}$$

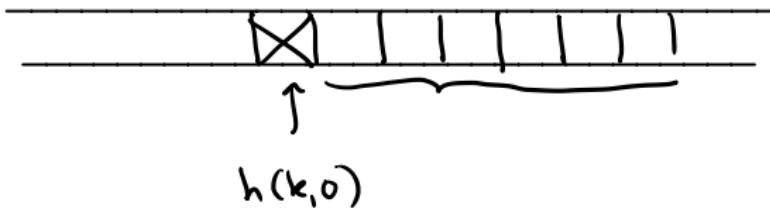
- ▶ h' ist eine übliche Hashfunktion.
- ▶ Die Verschiebung der nachfolgende Sondierungen ist linear von i abhängig.

Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist linear von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.



Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion.
 - ▶ Die Verschiebung der nachfolgenden Sondierungen ist linear von i abhängig.
 - ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
- ⇒ m verschiedene Sequenzen können erzeugt werden.

=

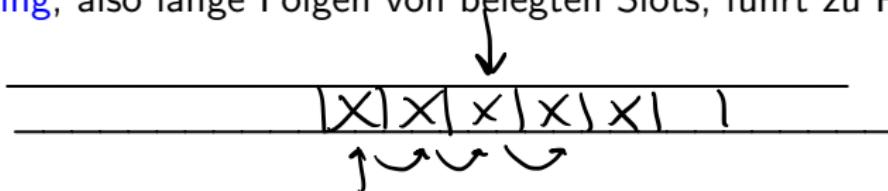
$m!$

Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist linear von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
⇒ m verschiedene Sequenzen können erzeugt werden.
- ▶ **Clustering**, also lange Folgen von belegten Slots, führt zu Problemen:



Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (\underline{h'(k)} + i) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion.

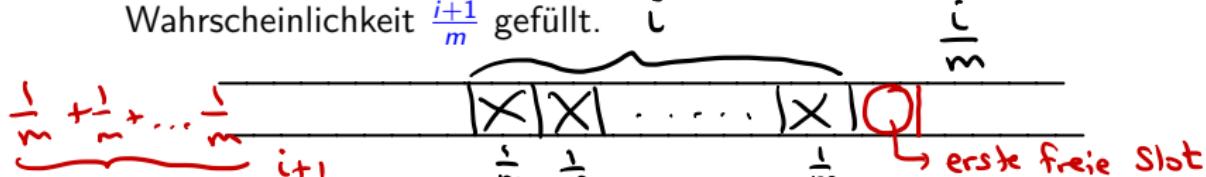
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist linear von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
⇒ m verschiedene Sequenzen können erzeugt werden.
- ▶ Clustering, also lange Folgen von belegten Slots, führt zu Problemen:
 - ▶ $\underline{h'(k)}$ bleibt konstant, aber der Offset wird jedes Mal um eins größer.

Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \quad (\text{für } i < m).$$

- ▶ h' ist eine übliche Hashfunktion.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist linear von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
- ⇒ m verschiedene Sequenzen können erzeugt werden.
- ▶ Clustering, also lange Folgen von belegten Slots, führt zu Problemen:
 - ▶ $h'(k)$ bleibt konstant, aber der Offset wird jedes Mal um eins größer.
 - ▶ Ein leerer Slot, dem i volle Slots vorausgehen, wird als nächstes mit Wahrscheinlichkeit $\frac{i+1}{m}$ gefüllt.



Lineares Sondieren

Hashfunktion beim linearen Sondieren

$$h(k, i) = (h'(k) + i) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist linear von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
⇒ m verschiedene Sequenzen können erzeugt werden.
- ▶ Clustering, also lange Folgen von belegten Slots, führt zu Problemen:
 - ▶ $h'(k)$ bleibt konstant, aber der Offset wird jedes Mal um eins größer.
 - ▶ Ein leerer Slot, dem i volle Slots vorausgehen, wird als nächstes mit Wahrscheinlichkeit $\frac{i+1}{m}$ gefüllt.
⇒ Lange Folgen tendieren dazu länger zu werden.

Quadratisches Sondieren

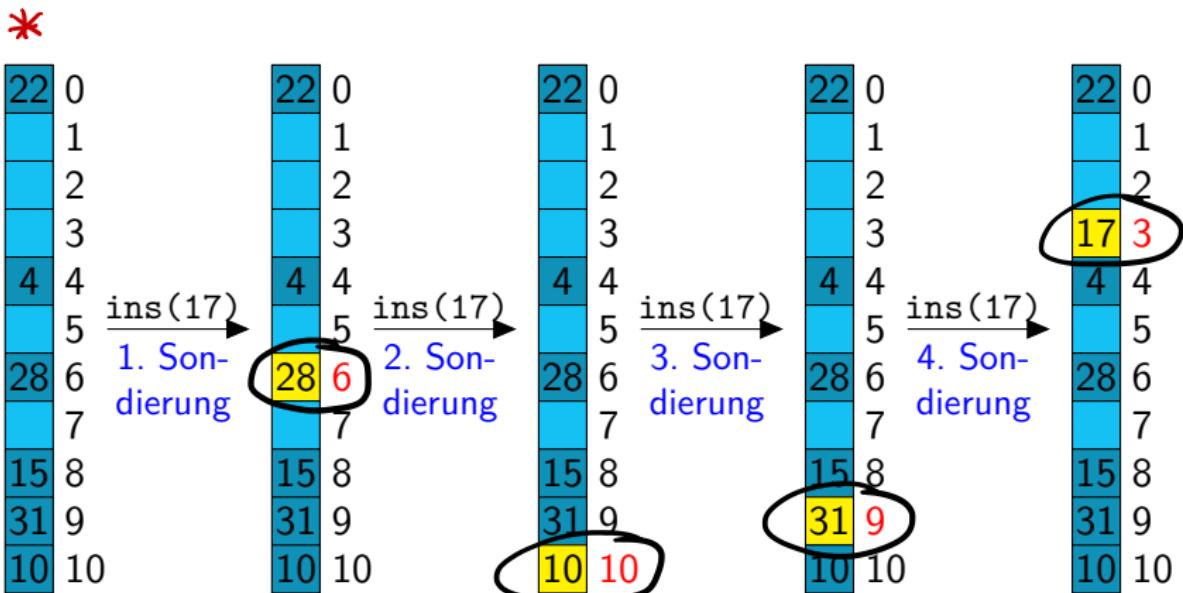
$$\cancel{h'(k) + i}$$

Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \quad (\text{für } i < m).$$

- ▶ k ist der Schlüssel
- ▶ i ist der Index im Sondierungssequenz
- ▶ h' ist eine übliche Hashfunktion, und
- ▶ $c_1, c_2 \in \mathbb{N} \setminus \{0\}$ geeignete Konstanten.

Quadratisches Sondieren: Beispiel



$$h'(k) = k \bmod 11$$

$$h(k, i) = (h'(k) + i + 3i^2) \bmod 11$$

$$c_1 = 1 \quad c_2 = 3$$

~~$h(17,0)$~~

$$h(k,i) = (h'(k) + i + 3i^2) \mod 11$$

$$h'(k) = k \mod 11$$

$$h(17,0) = 6 \mod 11 = 6$$

$$h(17,1) = (6 + 1 + 3) \mod 11 = 10$$

$$h(17,2) = (6 + 2 + 12) \mod 11 = 9$$

$$h(17,3) = (6 + 3 + 3 \cdot 3^2) \mod 11 = 3$$

Quadratisches Sondieren

Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \text{ (für } i < m\text{).}$$

- h' ist eine übliche Hashfunktion, $c_1, c_2 \neq 0$ Konstanten.

Quadratisches Sondieren

Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \text{ (für } i < m\text{).}$$

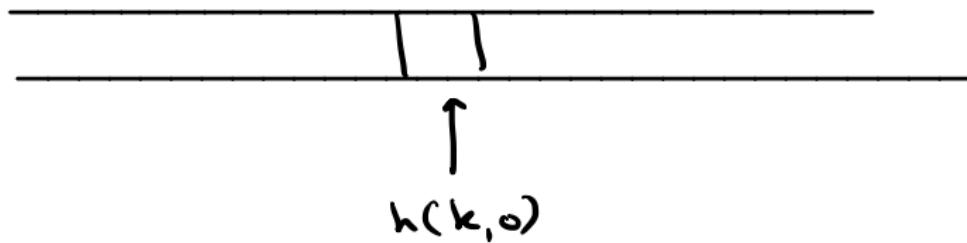
- ▶ h' ist eine übliche Hashfunktion, $c_1, c_2 \neq 0$ Konstanten.
- ▶ Die Verschiebung der nachfolgende Sondierungen ist quadratisch von i abhängig.

Quadratisches Sondieren

Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \quad (\text{für } i < m).$$

- ▶ h' ist eine übliche Hashfunktion, $c_1, c_2 \neq 0$ Konstanten.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist quadratisch von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.



Quadratisches Sondieren

Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \quad (\text{für } i < m).$$

- ▶ h' ist eine übliche Hashfunktion, $c_1, c_2 \neq 0$ Konstanten.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist quadratisch von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
- ⇒ Auch hier können m verschiedene Sequenzen erzeugt werden (wenn c_1, c_2 geeignet gewählt wurden).

$m!$ Permutationen

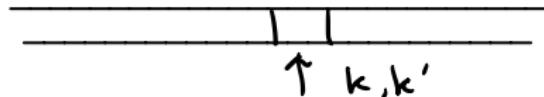
Quadratisches Sondieren

Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion, $c_1, c_2 \neq 0$ Konstanten.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist quadratisch von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
- ⇒ Auch hier können m verschiedene Sequenzen erzeugt werden (wenn c_1, c_2 geeignet gewählt wurden).
- ▶ Das Clustering von linearem Sondieren wird vermieden.

Quadratisches Sondieren



Hashfunktion beim quadratischen Sondieren

$$h(k, i) = (h'(k) + c_1 \cdot i + c_2 \cdot i^2) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h' ist eine übliche Hashfunktion, $c_1, c_2 \neq 0$ Konstanten.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist quadratisch von i abhängig.
- ▶ Die erste Sondierung bestimmt bereits die gesamte Sequenz.
- ⇒ Auch hier können m verschiedene Sequenzen erzeugt werden (wenn c_1, c_2 geeignet gewählt wurden).
- ▶ Das Clustering von linearem Sondieren wird vermieden.
- ▶ Jedoch tritt sekundäres Clustering immer noch auf:

$h(k, 0) = h(k', 0)$ verursacht $h(k, i) = h(k', i)$ für alle i .

!

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$h(k, i) = (\underline{h_1(k)} + \underline{i} \cdot \underline{h_2(k)}) \text{ mod } m$ (für $i < m$).

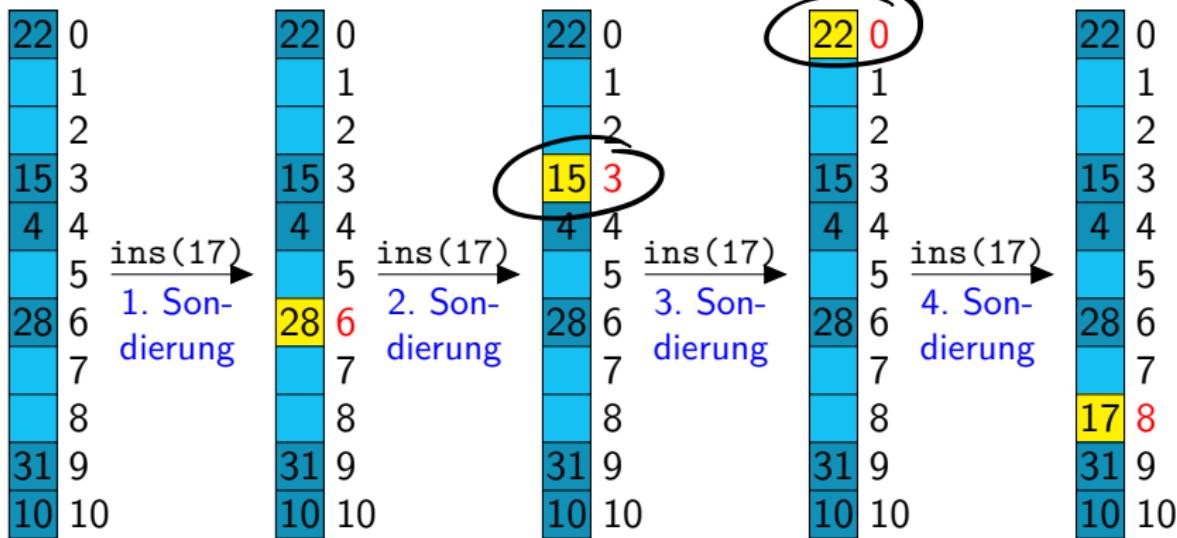
- h_1, h_2 sind übliche Hashfunktionen.

+ i

+ $i + 3i^2$

Doppeltes Hashing: Beispiel

*



- $h_1(k) = k \bmod 11$
- $h_2(k) = 1 + (k \bmod 10)$

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod 11$$

$$h_1(k) = k \bmod 11$$

$$h_2(k) = 1 + k \bmod 10$$

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod 11$$

insert (17):

$$h(17, 0) = (\underbrace{17 \bmod 11}_{= 6}) \bmod 11 = 6$$

$$h(17, 1) = (6 + 1 \cdot (\underbrace{1 + 17 \bmod 10}_{7})) \bmod 11 \\ 14 \bmod 11 = 3$$

$$h(17, 2) = (\underbrace{6 + 2 \cdot (\underbrace{1 + 17 \bmod 10}_{8})}_{\text{circled 6}}) \bmod 11 \\ = 22 \bmod 11$$

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m$ (für $i < m$).

- ▶ h_1, h_2 sind übliche Hashfunktionen.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.

$$\begin{aligned}
 & h_1(k) \bmod m && k, k' \\
 & (h_1(k) + h_2(k)) \bmod m && h_1(k) = \\
 & (h_1(k) + 2h_2(k)) \bmod m && h_1(k') \\
 & && \text{immerhin} \\
 & && h_2(k) \neq h_2(k')
 \end{aligned}$$

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.

- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.
- ⇒ Bessere Verteilung der Schlüssel in der Hashtabelle.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.
 - ⇒ Bessere Verteilung der Schlüssel in der Hashtabelle.
 - ⇒ Approximiert das gleichverteilte Hashing.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \quad (\text{für } i < m).$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.

- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.
 - ⇒ Bessere Verteilung der Schlüssel in der Hashtabelle.
 - ⇒ Approximiert das gleichverteilte Hashing.
- ▶ Sind h_2 und m relativ prim, wird die gesamte Hashtabelle abgesucht.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.
 - ⇒ Bessere Verteilung der Schlüssel in der Hashtabelle.
 - ⇒ Approximiert das gleichverteilte Hashing.
- ▶ Sind h_2 und m relativ prim, wird die gesamte Hashtabelle abgesucht.
 - ▶ Wähle z. B. $m = 2^k$ und h_2 so, dass sie nur ungerade Zahlen erzeugt.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

- ▶ h_1, h_2 sind übliche Hashfunktionen.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.
 - ⇒ Bessere Verteilung der Schlüssel in der Hashtabelle.
 - ⇒ Approximiert das gleichverteilte Hashing.
- ▶ Sind h_2 und m relativ prim, wird die gesamte Hashtabelle abgesucht.
 - ▶ Wähle z. B. $m = 2^k$ und h_2 so, dass sie nur ungerade Zahlen erzeugt.
- ▶ Jedes mögliche Paar $h_1(k)$ und $h_2(k)$ erzeugt eine andere Sequenz.

Doppeltes Hashing

Hashfunktion beim doppelten Hashing

$$h(k, i) = (h_1(k) + i \cdot h_2(k)) \bmod m \text{ (für } i < m\text{).}$$

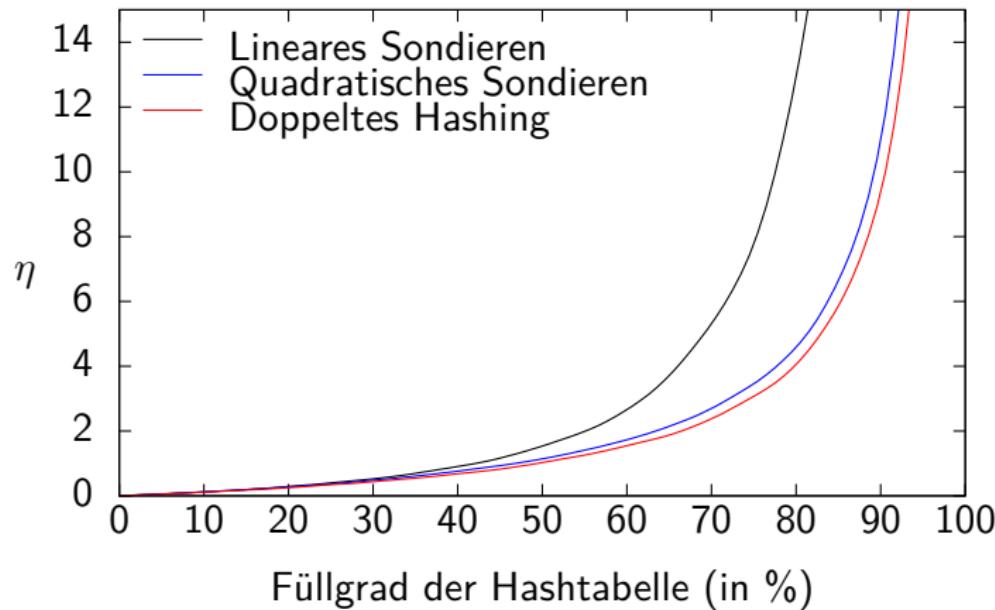
- ▶ h_1, h_2 sind übliche Hashfunktionen.
- ▶ Die Verschiebung der nachfolgenden Sondierungen ist von $h_2(k)$ abhängig.
- ▶ Die erste Sondierung bestimmt **nicht** die gesamte Sequenz.
 - ⇒ Bessere Verteilung der Schlüssel in der Hashtabelle.
 - ⇒ Approximiert das gleichverteilte Hashing.
- ▶ Sind h_2 und m relativ prim, wird die gesamte Hashtabelle abgesucht.
 - ▶ Wähle z. B. $m = 2^k$ und h_2 so, dass sie nur ungerade Zahlen erzeugt.
 - ▶ Jedes mögliche Paar $h_1(k)$ und $h_2(k)$ erzeugt eine andere Sequenz.
- ⇒ Daher können m^2 verschiedene Permutationen erzeugt werden.

Praktische Effizienz von Doppeltem Hashing

- ▶ Hashtabelle mit 538 051 Einträgen (Endfüllgrad 99,95%)

Praktische Effizienz von Doppeltem Hashing

- ▶ Hashtabelle mit 538 051 Einträgen (Endfüllgrad 99,95%)
- ▶ Mittlere Anzahl Kollisionen η pro Einfügen in die Hashtabelle:



Effizienz der offenen Adressierung

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 2 Sondierungen nötig.

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 2 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 10 Sondierungen nötig.

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 2 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 10 Sondierungen nötig.

Erfolgreiche Suche

Die erfolgreiche Suche benötigt $O\left(\frac{1}{\alpha} \cdot \ln \frac{1}{1-\alpha}\right)$ im Average-Case.

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 2 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 10 Sondierungen nötig.

Erfolgreiche Suche

Die erfolgreiche Suche benötigt $O\left(\frac{1}{\alpha} \cdot \ln \frac{1}{1-\alpha}\right)$ im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 1,39 Sondierungen nötig.

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 2 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 10 Sondierungen nötig.

Erfolgreiche Suche

Die erfolgreiche Suche benötigt $O\left(\frac{1}{\alpha} \cdot \ln \frac{1}{1-\alpha}\right)$ im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 1,39 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 2,56 Sondierungen nötig.

Effizienz der offenen Adressierung

Unter der Annahme von gleichverteiltem Hashing gilt:

Erfolglose Suche

Die erfolglose Suche benötigt $O\left(\frac{1}{1-\alpha}\right)$ Zeit im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 2 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 10 Sondierungen nötig.

Erfolgreiche Suche

Die erfolgreiche Suche benötigt $O\left(\frac{1}{\alpha} \cdot \ln \frac{1}{1-\alpha}\right)$ im Average-Case.

- ▶ Bei 50% Füllung sind durchschnittlich 1,39 Sondierungen nötig.
- ▶ Bei 90% Füllung sind durchschnittlich 2,56 Sondierungen nötig.

Bei der Verkettung hatten wir $\Theta(1 + \alpha)$ in beiden Fällen erhalten.

Analyse der erfolglosen Suche (I)

Annahmen

- ▶ Betrachte eine **zufällig** erzeugte Sondierungssequenz für Schlüssel k .

$$h(k_0) \quad h(k_1) \quad h(k_2) \quad \dots \dots \dots$$

Analyse der erfolglosen Suche (I)

Annahmen

- ▶ Betrachte eine **zufällig** erzeugte Sondierungssequenz für Schlüssel k .
- ▶ Annahme: jede mögliche Sondierungssequenz hat die **gleiche Wahrscheinlichkeit** $\frac{1}{m!}$, da es $m!$ mögliche Permutationen von den Positionen $0, \dots, m-1$ gibt.

$$\Pr = \frac{1}{m!}$$

$m!$ mögliche Permutation

$h(k_{i,0}) \ h(k_{i,1}) \ \dots \ h(k_{i,m-1}) \dots$

Analyse der erfolglosen Suche (I)

Annahmen

- ▶ Betrachte eine **zufällig** erzeugte Sondierungssequenz für Schlüssel k .
- ▶ Annahme: jede mögliche Sondierungssequenz hat die **gleiche Wahrscheinlichkeit** $\frac{1}{m!}$, da es $m!$ mögliche Permutationen von den Positionen $0, \dots, m-1$ gibt.
- ▶ Bemerkung: dies ist nicht unrealistisch, da im Idealfall die Sondierungssequenz für k möglichst unabhängig ist von der Sondierungssequenz für k' , $k \neq k'$.

Analyse der erfolglosen Suche (I)

Annahmen

- ▶ Betrachte eine **zufällig** erzeugte Sondierungssequenz für Schlüssel k .
- ▶ Annahme: jede mögliche Sondierungssequenz hat die **gleiche Wahrscheinlichkeit** $\frac{1}{m!}$, da es $m!$ mögliche Permutationen von den Positionen $0, \dots, m-1$ gibt.
- ▶ Bemerkung: dies ist nicht unrealistisch, da im Idealfall die Sondierungssequenz für k möglichst unabhängig ist von der Sondierungssequenz für k' , $k \neq k'$.
- ▶ Wir nehmen (wie vorher) an, dass die Berechnung von Hashwerten in $O(1)$ liegt.

$$h(k, i) \in O(1)$$

Analyse der erfolglosen Suche (II)

Erfolglose Suche

Eine Suche für k ist **erfolglos** wenn für i alle Slots $h(k, 0), \dots, h(k, i-1)$ belegt sind, jedoch unterschiedlich von k sind, und $h(k, i)$ ist unbelegt.

Erfolgslose Suche

suche für k ist erfolglos, d.h.

$$\underbrace{T[h(k,0)]}_{\text{besetzt}}, \underbrace{T[h(k,1)]}_{\text{besetzt}}, \dots, \underbrace{T[h(k,i-1)]}_{\text{besetzt}}$$

$$T[h(k,i)] = \text{NULL} \quad \begin{matrix} \leftarrow \\ \uparrow \\ \text{erster freier Platz} \end{matrix}$$

Also: erwartete Anzahl der Sondierungen für erfolgslose Suche nach k = 1 + erwartete Anzahl der belegten Positionen bis erster freier Platz

Lemma sei $h: U \times \{0, \dots, m-1\} \rightarrow \{0, \dots, m-1\}$

und k so, dass $h(k,0), \dots, h(k,m-1)$ eine zufällige Permutation von $\{0, \dots, m-1\}$ ist

Seien n Positionen in T schon besetzt.

$n < m$.

Dann: $1 + \mathbb{E} [\min \{i \in \mathbb{N} \mid h(k,i) \text{ ist frei}\}]$

$$\leq \frac{m+1}{m-n+1} \in O\left(\frac{1}{1-\alpha}\right)$$

Beweis: $X = \min \{ i \in \mathbb{N} \mid h(k,i) \text{ ist frei} \}$

Ergebnis $X \geq i$ gdw. $h(k,0), \dots, h(k,i-1)$ sind alle belegt. Also

$$\underbrace{\{h(k,0), \dots, h(k,i-1)\}}_{\text{zufällige } i\text{-elementige Teilmenge von } \{0, \dots, m-1\}} \subseteq \underbrace{\{j \mid h(k,j) \text{ ist belegt}\}}_{\text{diese Menge enthält } n \text{ Elemente}}$$

zufällige i -elementige Teilmenge von $\{0, \dots, m-1\}$

$\Pr \{ X \geq i \} =$ Anzahl der Möglichkeiten i Positionen aus n belegte Positionen zu wählen

Anzahl der Möglichkeiten i Positionen aus alle m verfügbare Positionen zu wählen

$$\Pr \{ X \geq i \} = \frac{\binom{n}{i}}{\binom{m}{i}} = \frac{\frac{n!}{i!(n-i)!}}{\frac{m!}{i!(m-i)!}} = \frac{n!}{m!} \cdot \frac{(m-i)!}{(n-i)!}$$

$$\mathbb{E}(X) = \sum_{i=1}^8 \Pr \{ X \geq i \} =$$

$$\sum_{i=1}^n \Pr \{ X \geq i \}$$

(* $\Pr(X \geq n+1) = 0$)
da n Positionen belegt sind *)

$$\sum_{i=1}^n \Pr\{X \geq i\} = \frac{n!}{m!} \sum_{i=1}^n \frac{(m-i)!}{(n-i)!}$$

= (+ Übungsaufgabe +)

$$\frac{n}{m-n+1} = E(X)$$

$$1 + E(X) = \frac{m-n+1}{m-n+1} + \frac{n}{m-n+1} = \frac{m+1}{m-n+1}$$

$$\leftarrow O\left(\frac{m}{m-n}\right) =$$

$$O\left(\frac{1}{1-\frac{n}{m}}\right) = \boxed{O\left(\frac{1}{1-\alpha}\right)}$$

Analyse der erfolglosen Suche (II)

Erfolglose Suche

Eine Suche für k ist **erfolglos** wenn für i alle Slots $h(k, 0), \dots, h(k, i-1)$ belegt sind, jedoch unterschiedlich von k sind, und $h(k, i)$ ist unbelegt.

Sei X die Anzahl der belegten Positionen bis eine freie Position gefunden ist:

$$X = \min \{ i \in \mathbb{N} : h(k, i) \text{ ist unbelegt} \}.$$

Sei $E[X]$ der Erwartungswert von X .

Analyse der erfolglosen Suche (II)

Erfolglose Suche

Eine Suche für k ist **erfolglos** wenn für i alle Slots $h(k, 0), \dots, h(k, i-1)$ belegt sind, jedoch unterschiedlich von k sind, und $h(k, i)$ ist unbelegt.

Sei X die Anzahl der belegten Positionen bis eine freie Position gefunden ist:

$$X = \min \{ i \in \mathbb{N} : h(k, i) \text{ ist unbelegt} \}.$$

Sei $E[X]$ der Erwartungswert von X .

Dann: die Average-Case Komplexität einer erfolglosen Suche ist $1 + E[X]$.

Analyse der erfolglosen Suche (II)

Erfolglose Suche

Eine Suche für k ist **erfolglos** wenn für i alle Slots $h(k, 0), \dots, h(k, i-1)$ belegt sind, jedoch unterschiedlich von k sind, und $h(k, i)$ ist unbelegt.

Sei X die Anzahl der belegten Positionen bis eine freie Position gefunden ist:

$$X = \min \{ i \in \mathbb{N} : h(k, i) \text{ ist unbelegt} \}.$$

Sei $E[X]$ der Erwartungswert von X .

Dann: die Average-Case Komplexität einer erfolglosen Suche ist $1 + E[X]$.

Lemma

$$E[X] \leq \frac{n}{m-n+1}.$$

Beweis: in der Vorlesung.

Nachtrag:

Sei k_1, k_2, \dots, k_n die Folge der eingefügten Schlüsseln

average-case Komplexität der erfolgreichen Suche nach Schlüsseln k_{j+1}

$$= E \left[\begin{array}{l} \text{Anzahl der benötigten Sondierungen} \\ \text{beim Einfügen von } k_{j+1} \text{ in } T \end{array} \right]$$

$$= E \left[\min \left\{ i \in \mathbb{N} \mid h(k_{j+1}, i) \text{ ist frei} \right. \right. \\ \left. \left. \text{und } T \text{ enthält schon } j \text{ Schlüssel } k_1, \dots, k_j \right\} \right]$$

$$\leq (* \text{ Anteil der freien Positionen ist } \frac{m-j}{m})$$

bzw. alle Positionen

$$\frac{m}{m-j}$$

Also: erwartete Zeit für Schlüssel k_{j+1}

$$\text{ist} \quad \cap \quad \frac{m}{m-j}$$

Wir betrachten jetzt die mittlere Zeit für alle n Schlüssel die sich in T befinden:

$$\begin{aligned}
 &= q \cdot \left(H_3 - H_{m-n} \right) \\
 &= q \cdot \sum_{k=m-n+1}^m \frac{1}{k} \\
 &= q \cdot \sum_{i=0}^{n-1} \frac{1}{3-i} \\
 &= q \cdot \sum_{i=0}^{n-1} \frac{1}{m-(n-i)} \\
 &= q \cdot \sum_{i=0}^{n-1} \frac{1}{m} + \dots + \frac{1}{m-(n-1)} \\
 &\quad (\star \quad \alpha = \frac{1}{m} \quad \star) \\
 &H_n = \sum_{i=1}^n \frac{1}{i} \quad (\star \quad H_n \in O(\ln(n)) \quad \star)
 \end{aligned}$$

$$\in \mathcal{O}\left(\frac{1}{\epsilon} (\ln(m) - \ln(m-n))\right)$$

$$\in \mathcal{O}\left(q\tau \cdot \log\left(\frac{3}{\delta-\gamma}\right)\right)$$

$$e^{-\sigma \left(\frac{1}{\alpha} \cdot \ln \left(\frac{1}{1-\alpha} \right) \right)}$$

Analyse der erfolglosen Suche (II)

Erfolglose Suche

Eine Suche für k ist **erfolglos** wenn für i alle Slots $h(k, 0), \dots, h(k, i-1)$ belegt sind, jedoch unterschiedlich von k sind, und $h(k, i)$ ist unbelegt.

Sei X die Anzahl der belegten Positionen bis eine freie Position gefunden ist:

$$X = \min \{ i \in \mathbb{N} : h(k, i) \text{ ist unbelegt} \}.$$

Sei $E[X]$ der Erwartungswert von X .

Dann: die Average-Case Komplexität einer erfolglosen Suche ist $1 + E[X]$.

Lemma

$$E[X] \leq \frac{n}{m-n+1}.$$

Beweis: in der Vorlesung. Damit: $1 + E[X] \leq 1 + \frac{n}{m-n+1} \in O\left(\frac{1}{1-\alpha}\right)$.

Analyse der erfolgreichen Suche (I)

- ▶ Sei Schlüssel k_i der i -te eingefügte Schlüssel in der Hashtabelle.

Analyse der erfolgreichen Suche (I)

- ▶ Sei Schlüssel k_i der i -te eingefügte Schlüssel in der Hashtabelle.
- ▶ Betrachte eine erfolgreiche Suche für Schlüssel k_{i+1} .

Analyse der erfolgreichen Suche (I)

- ▶ Sei Schlüssel k_i der i -te eingefügte Schlüssel in der Hashtabelle.
- ▶ Betrachte eine erfolgreiche Suche für Schlüssel k_{i+1} .
- ▶ Sei X_i die Anzahl der Sondierungen beim Einfügen vom Schlüssel k_i .

Analyse der erfolgreichen Suche (I)

- ▶ Sei Schlüssel k_i der i -te eingefügte Schlüssel in der Hashtabelle.
- ▶ Betrachte eine erfolgreiche Suche für Schlüssel k_{i+1} .
- ▶ Sei X_i die Anzahl der Sondierungen beim Einfügen vom Schlüssel k_i .
- ▶ Im Schnitt, braucht eine erfolgreiche Suche für k_i , $E[X_i]$ Zeiteinheiten.

Analyse der erfolgreichen Suche (I)

- ▶ Sei Schlüssel k_i der i -te eingefügte Schlüssel in der Hashtabelle.
- ▶ Betrachte eine erfolgreiche Suche für Schlüssel k_{i+1} .
- ▶ Sei X_i die Anzahl der Sondierungen beim Einfügen vom Schlüssel k_i .
- ▶ Im Schnitt, braucht eine erfolgreiche Suche für k_i , $E[X_i]$ Zeiteinheiten.
- ▶ Die Average-Case Zeitkomplexität für eine erfolgreiche Suche ist:

$$\frac{1}{n} \sum_{i=0}^{n-1} E[X_{i+1}].$$

Analyse der erfolgreichen Suche (I)

- ▶ Sei Schlüssel k_i der i -te eingefügte Schlüssel in der Hashtabelle.
- ▶ Betrachte eine erfolgreiche Suche für Schlüssel k_{i+1} .
- ▶ Sei X_i die Anzahl der Sondierungen beim Einfügen vom Schlüssel k_i .
- ▶ Im Schnitt, braucht eine erfolgreiche Suche für k_i , $E[X_i]$ Zeiteinheiten.
- ▶ Die Average-Case Zeitkomplexität für eine erfolgreiche Suche ist:

$$\frac{1}{n} \sum_{i=0}^{n-1} E[X_{i+1}]$$

Lemma

$$\frac{1}{n} \sum_{i=0}^{n-1} E[X_{i+1}] \in O\left(\frac{1}{\alpha} \cdot \ln \frac{1}{1-\alpha}\right).$$

Beweis: in der Vorlesung.

Nächste Vorlesung

Nächste Vorlesung

Freitag 15. Juni, 13:15 (Hörsaal H01). Bis dann!